Дерево оптимального поиска

Пусть двоичное дерево поиска содержит ключи $k_1, k_2, k_2, \ldots, k_n$.

Задача № 1. Пусть каждый пользователь разыскивает только один из имеющихся в дереве ключей, причем, известна вероятность того, что пользователя интересует именно i –й ключ:

$$p_i = P\big|_{x=k_i}.$$

То, что пользователя интересуют только имеющиеся ключи, выражается равенством

$$\sum_{i=1}^{n} p_i = 1.$$

Требуется построить такое дерево, чтобы

$$P_I = \sum_{i=1}^n p_i h_i \rightarrow \min,$$

 h_i – уровень вершины i (число, на единицу большее глубины).

Задача № 2. Пусть каждый пользователь разыскивает ключ, который может либо присутствовать, либо отсутствовать в дереве. Вероятность успешного поиска сформулирована выше, а вероятность неудачи есть

$$q_i = P|_{k_i < x < k_{i+1}}, i = 1, 2, 3, ..., n-1,$$

 $q_0 = P|_{x < k_1}, q_n = P|_{x > k_n}$

То, что в дереве могу быть только интересующие или не интересующие пользователя ключи, выражается равенством

$$\sum_{i=1}^{n} p_i + \sum_{j=0}^{n} q_j = 1.$$

Требуется построить такое дерево, чтобы

$$P_{\Sigma} = P_I + P_E = \sum_{i=1}^{n} p_i h_i + \sum_{j=0}^{n} q_j h_j' \rightarrow \min$$

 p_i – вероятность обращения к i –му ключу в дереве;

 q_i – вероятность обращения к отсутствующим ключам, «расположенным» между i –м и (i-1)

м ключами в дереве;

 q_0 — вероятность обращения к отсутствующим ключам, «меньшим», чем 0—й (по номеру) ключ в дереве;

 q_n — вероятность обращения к отсутствующим ключам, «большим», чем n—й (по номеру) ключ в дереве;

 $h_{j}^{'}$ – уровень специальной вершины j.

Разумеется, каждая из этих задач может быть решена. Однако, величины p_i и q_j не могут быть известны точно. Они могут быть оценены приближенно, на основе статистики обращения пользователей к дереву поиска:

$$p_{m} = \frac{a_{m}}{\sum_{i=1}^{n} a_{i} + \sum_{j=0}^{n} b_{j}}, \qquad q_{m} = \frac{b_{m}}{\sum_{i=1}^{n} a_{i} + \sum_{j=0}^{n} b_{j}},$$

где:

 a_i – количество обращений к i – му ключу в дереве,

 b_i — количество обращений к несуществующим ключам, «расположенным» между i—м и (i-1)—м ключами в дереве,

 b_0 – количество обращений к несуществующим ключам, «меньшим», чем 0–й (по номеру) ключ в дереве,

 b_n – количество обращений к отсутствующим ключам, «большим», чем n –й ключ в дереве.

Задача № 3. Требуется построить такое дерево, чтобы

$$P = P_I' + P_E' = \sum_{i=1}^{n} a_i h_i + \sum_{j=0}^{n} b_j h_j' \rightarrow \min$$

Функция, которая минимизируется в задаче № 3, пропорциональна функции в задаче № 2. Коэффициент пропорциональности

$$\sum_{i=1}^{n} a_i + \sum_{j=0}^{n} b_j$$

от вида дерева не зависит.

Утверждение.

$$P = P_L + W + P_R$$
, где $W = \sum_{i=1}^n a_i + \sum_{j=0}^n b_j$.

P называется *длиной пути* дерева, *W* называется *весом* дерева.

Доказательство.

$$\sum_{i=1}^{n} a_{i}h_{i} + \sum_{j=0}^{n} b_{j}h_{j}' =$$

$$= \sum_{i=1}^{m-1} a_{i}h_{i} + a_{m}\underbrace{h_{m}}_{=1} + \sum_{i=m+1}^{n} a_{i}h_{i} + \sum_{j=0}^{m-1} b_{j}h_{j}' + \sum_{j=m}^{n} b_{j}h_{j}' =$$

$$= \sum_{i=1}^{m-1} a_{i}h_{i} + \sum_{j=0}^{m-1} b_{j}h_{j}' + \sum_{i=m+1}^{n} a_{i}h_{i} + \sum_{j=m}^{n} b_{j}h_{j}' + a_{m} =$$

$$\underbrace{\left(\sum_{i=1}^{m-1} a_{i}(h_{i}-1) + \sum_{j=0}^{m-1} b_{j}(h_{j}'-1)\right)}_{=P_{L}} + \underbrace{\left(\sum_{i=m+1}^{n} a_{i}(h_{i}-1) + \sum_{j=m}^{n} b_{j}(h_{j}'-1)\right)}_{=P_{R}} + \underbrace{\sum_{i=m+1}^{n} a_{i} + \sum_{j=m}^{n} b_{j}}_{=W} + a_{m} =$$

$$= P_{L} + P_{R} + \underbrace{\sum_{i=1}^{n} a_{i} + \sum_{j=0}^{n} b_{j}}_{=W}$$

Замечание.

$$P_{\Sigma} = \frac{P}{W}$$
.

Алгоритм построения дерева

Пусть T_{ij} – оптимальное поддерево, составленное из ключей $k_{i+1}, k_{i+2}, \ldots, k_j$ (ключ k_i в дереве отсутствует).

Пусть вес этого дерева – w_{ij} , целевая функция (длина пути) – p_{ij} .

Ясно, что $w_{0n} = W$, $p_{0n} = P$.

$$w_{ij} = \sum_{s=i+1}^{j} a_s + \sum_{t=i}^{j} b_t$$
, $p_{ij} = \sum_{s=i+1}^{j} a_s h_s + \sum_{t=i}^{j} b_t h_t'$.

Тогда:

$$\begin{split} w_{ii} &= b_i, \quad 0 \leq i \leq n \,, \\ w_{ij} &= w_{i,j-1} + a_j + b_j, \quad 0 \leq i < j \leq n \,, \\ p_{ii} &= w_{ii}, \quad 0 \leq i \leq n \,, \\ p_{ij} &= w_{ij} + \min_{k: \ i < k \leq j} \left(p_{i,k-1} + p_{kj} \right), \quad 0 \leq i < j \leq n \,. \end{split}$$

 r_{ij} — то значение k , при котором достигается этот ${f min}.$

Пример

Пусть n = 4, а числа пользовательских обращений представлены в таблице:

i	0	1	2	3	4
a_i		20	10	5	3
b_i	64	32	16	8	4

Без затруднений и объяснений заполняется таблица

$w_{00} = 64$	$w_{01} = 64 + 52 = 116$	$w_{02} = 116 + 26 = 142$	$w_{03} = 142 + 13 = 155$	$w_{04} = 155 + 7 = 162$
	$w_{11} = 32$	$w_{12} = 32 + 26 = 58$	$w_{13} = 58 + 13 = 71$	$w_{14} = 71 + 7 = 78$
		$w_{22} = 16$	$w_{23} = 16 + 13 = 29$	$w_{24} = 29 + 7 = 36$
			$w_{33} = 8$	$w_{34} = 8 + 7 = 15$
				$w_{44} = 4$

Формирование величин p_{ij} , r_{ij} несколько сложнее и требует пояснений.

Разница индексов – единица:

$$p_{01} = w_{01} + \min(p_{00} + p_{11}) = 116 + 96 = 212, \quad r_{01} = 1,$$

$$p_{12} = w_{12} + \min(p_{11} + p_{22}) = 58 + 48 = 106, \quad r_{12} = 2,$$

$$p_{23} = w_{23} + \min(p_{22} + p_{33}) = 29 + 24 = 53, \quad r_{23} = 3,$$

$$p_{34} = w_{34} + \min(p_{33} + p_{44}) = 15 + 12 = 27, \quad r_{34} = 4,$$

Разница индексов – двойка:

$$p_{02} = w_{02} + \min(p_{00} + p_{12}, p_{01} + p_{22}) = 142 + \min(64 + 106, 212 + 16) = 142 + 170 = 312,$$

 $r_{02} = 1,$
 $p_{12} = w_{12} + \min(p_{11} + p_{22}, p_{12} + p_{22}) = 71 + \min(32 + 53, 106 + 8) = 71 + 85 = 156$

$$p_{13} = w_{13} + \min(p_{11} + p_{23}, p_{12} + p_{33}) = 71 + \min(32 + 53, 106 + 8) = 71 + 85 = 156,$$

 $r_{13} = 2,$

$$p_{24} = w_{24} + \min(p_{22} + p_{34}, p_{23} + p_{44}) = 36 + \min(16 + 27, 53 + 4) = 36 + 43 = 79,$$

 $r_{24} = 3,$

Разница индексов – тройка:

$$p_{03} = w_{03} + \min(p_{00} + p_{13}, p_{01} + p_{23}, p_{02} + p_{33}) = 155 +$$

+ $\min(64 + 156, 212 + 53, 312 + 8) = 155 + 220 = 375,$

$$r_{03} = 1$$
,

$$p_{14} = w_{14} + \min(p_{11} + p_{24}, p_{12} + p_{34}, p_{13} + p_{44}) = 78 + \min(32 + 79, 106 + 27, 156 + 4) = 78 + 111 = 189,$$

$$r_{14}=2\,,$$

$$p_{14} = w_{14} + \min(p_{11} + p_{24}, p_{12} + p_{34}, p_{13} + p_{44}) = 78 +$$

Разница индексов – четверка:

$$p_{04} = w_{04} + \min(p_{00} + p_{14}, p_{01} + p_{24}, p_{02} + p_{34}, p_{03} + p_{44}) = 162 + \min(64 + 189, 212 + 79, 312 + 27, 375 + 4) = 162 + 253 = 415,$$

 $r_{04} = 1$,

$p_{11} = 32$	$w_{12} = 32 + 26 = 58$	$w_{13} = 58 + 13 = 71$	$w_{14} = 71 + 7 = 78$
	$p_{22} = 16$	$w_{23} = 16 + 13 = 29$	$w_{24} = 29 + 7 = 36$
		$p_{33} = 8$	$w_{34} = 8 + 7 = 15$
			$p_{44} = 4$